



به نام خدا
دانشگاه تهران



دانشکده مهندسی برق و کامپیوتر

درس مدل های مولد عمیق
تمرین اول

کیانا هوشانفر

۸۱۰۱۰۱۳۶۱

Problem ①:

$$1. \quad P(X_2, X_3 | Z_5) = ?$$

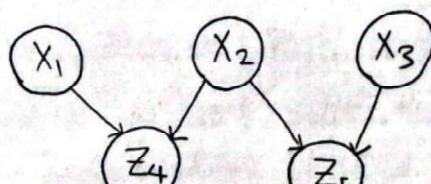
$$P(X_2, X_3 | Z_5) = \frac{P(X_2, X_3, Z_5)}{P(Z_5)} \quad \underline{Z_5 = X_2 \oplus X_3} \quad \frac{P(X_2, X_3)}{P(Z_5)}$$

$$\Rightarrow \begin{cases} P(Z_5=0) = P(X_2=0, X_3=0) + P(X_2=1, X_3=1) = (1-q_f)^2 + q_f^2 \\ P(Z_5=1) = P(X_2=0, X_3=1) + P(X_2=1, X_3=0) = 2q_f(1-q_f) \end{cases}$$

$$\boxed{Z_5=0} \Rightarrow \left\{ \begin{array}{l} P(X_2=0, X_3=0 | Z_5=0) = \frac{(1-q_r)^4}{(1-q_r)^4 + q_r^4} \\ P(X_2=1, X_3=1 | Z_5=0) = \frac{q_r^4}{(1-q_r)^4 + q_r^4} \\ P(X_2=1, X_3=0 | Z_5=0) = 0 \\ P(X_2=0, X_3=1 | Z_5=0) = 0 \end{array} \right.$$

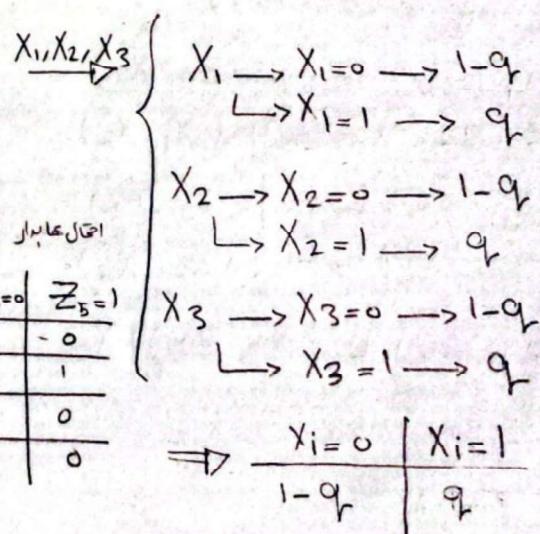
$$\boxed{Z_5=1} \rightarrow \left\{ \begin{array}{l} P(X_2=0, X_3=0 | Z_5=1) = 0 \\ P(X_2=1, X_3=1 | Z_5=1) = 0 \\ P(X_2=1, X_3=0 | Z_5=1) = \frac{1}{r} \\ P(X_2=0, X_3=1 | Z_5=1) = \frac{1}{r} \end{array} \right.$$

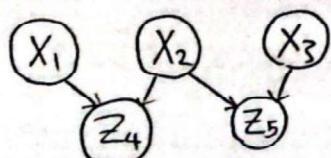
2.



$Z_4 \rightarrow$	X_1	X_2	$Z_4 = 0$	$Z_4 = 1$
	0	0	1	0
	0	1	0	1
	1	0	0	1
	1	1	1	0

امانی و بیانی می‌گردند و این از دلایلی است که در اینجا مذکور شده است.





Independence relations:

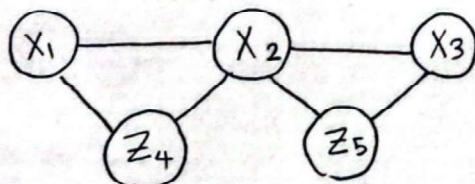
$$\begin{cases} X_1 \perp (X_2, X_3, Z_5) \\ X_2 \perp (X_1, X_3) \\ X_3 \perp (X_1, X_2, Z_4) \end{cases}$$

$$\begin{cases} X_1 \perp X_2 | (X_3, Z_5) \\ X_1 \perp Z_5 | (X_2, X_3, Z_4) \\ X_2 \perp X_3 | (X_1, Z_4) \\ X_3 \perp Z_4 | (X_1, X_2, Z_5) \\ Z_4 \perp Z_5 | (X_1, X_2, X_3) \end{cases}$$

$$\begin{cases} X_1 \perp (X_2, X_3) | Z_5 \\ X_1 \perp (X_2, Z_5) | X_3 \\ X_3 \perp (X_1, X_2) | Z_4 \\ X_3 \perp (X_2, Z_4) | X_1 \\ X_1 \perp (X_3, Z_5) | (X_2, Z_4) \\ X_3 \perp (X_1, Z_4) | (X_2, Z_5) \\ Z_4 \perp (X_3, Z_5) | (X_1, X_2) \\ Z_5 \perp (X_1, Z_4) | (X_2, X_3) \end{cases}$$

$$(X_1, Z_4) \perp (X_3, Z_5) | X_2$$

3.



: undirected graphical model

Potential functions:

$$\begin{aligned} \text{maximal max-cliques: } & \varphi_{142}(X_1, Z_4, X_2) = P(X_1)P(X_2)P(Z_4 | X_1, X_2) \stackrel{\text{OR}}{=} P(X_1)P(Z_4 | X_1, X_2) \\ & \varphi_{253}(X_2, Z_5, X_3) = P(X_3)P(Z_5 | X_2, X_3) \stackrel{\text{OR}}{=} P(X_3)P(X_2)P(Z_5 | X_2, X_3) \end{aligned}$$

Independence relations:

$$\begin{cases} X_1 \perp (X_3, Z_5) | (Z_4, X_2) \\ Z_4 \perp (X_3, Z_5) | (X_1, X_2) \\ (X_1, Z_4) \perp X_3 | (X_2, Z_5) \\ (X_1, Z_4) \perp Z_5 | (X_2, X_3) \end{cases}$$

$$\begin{cases} X_1 \perp X_3 | (X_2, Z_4, Z_5) \\ X_1 \perp Z_5 | (X_2, X_3, Z_4) \\ Z_4 \perp Z_5 | (X_1, X_2, X_3) \\ Z_4 \perp X_3 | (X_1, X_2, Z_5) \end{cases}$$

$$(X_1, Z_4) \perp (X_3, Z_5) | X_2$$

4.

① $q \in \{0, 1\}$:

تصویریار لعنتی ایستادن سونده درستیج استقلال ها X_1, X_4, X_5 است، $q \in \{0, 1\}$
 $Z_5 \perp X_3, Z_4 \perp X_1$ (" " " " " Z_5, Z_4)

② $0 < q < 1$:

$$\text{for independence: } P(Z_5=1) = P(Z_5=1 | X_3=0) = P(Z_5=1 | X_3=1)$$

$$P(Z_5=1) = \underbrace{P(Z_5=1 | X_3=0)}_q P(X_3=0) + \underbrace{P(Z_5=1 | X_3=1)}_{1-q} P(X_3=1)$$

$$\Rightarrow P(Z_5=1) = q(1-q)$$

استقلال های مجزا نظر بزار $0 < q < 1$ بطری برقرار است و این $q_f = q_p$ است. از این دو نتیجه مجزا است که Z_5 و Z_4 marginal independencies دارند.

Problem ②:

→ Figure 1:

1. season \perp chills \rightarrow False \rightarrow give FLU
2. season \perp chills | FLU \rightarrow True \rightarrow give Headache
3. Season \perp Headache | flu \rightarrow False \rightarrow given Dehy
4. Season \perp Headache | FLU, Dehydration \rightarrow True \rightarrow given Dehy, FLU
5. Season \perp Nausea | Dehydration \rightarrow False \rightarrow given Nausea
6. Season \perp Nausea | Dehydration, Headache \rightarrow True \rightarrow Headache, Dehy
7. FLU \perp Dehydration \rightarrow False \rightarrow (FLU \leftarrow season \rightarrow Dehy) \rightarrow given season
8. FLU \perp Dehydration | Season, Headache \rightarrow False \rightarrow headach given V-structure
9. FLU \perp Dehydration | Season \rightarrow True \rightarrow given headach
10. FLU \perp Dehydration | Season, Nausea \rightarrow False \rightarrow given Nausea
11. Chills \perp Nausea \rightarrow False \rightarrow given Nausea
12. Chills \perp Nausea | Headache \rightarrow False \rightarrow Headache given FLU

→ Figure 2:

$$1. P(S, F, D, C, H, N, Z) = P(S)P(F|S)P(D|S)P(C|F)P(H|F, D)P(Z|H)P(N|D, Z)$$

$$2. = \frac{1}{Z} \varphi_1(S)\varphi_2(F)\varphi_3(D)\varphi_4(C)\varphi_5(H)\varphi_6(N)\varphi_7(Z)\varphi_8(S, F)\varphi_9(S, D) \\ \varphi_{10}(F, C)\varphi_{11}(F, H)\varphi_{12}(D, H)\varphi_{13}(D, N)\varphi_{14}(H, Z)\varphi_{15}(N, Z)$$

→ Table 1:

$$1. P(Flu=True) = \sum_{\text{Season}} P(Flu=True | \text{Season}) \\ = \sum_S P(Flu=True | S=S) P(S=S) \\ = P(Flu=True | S=\text{winter})P(S=\text{winter}) + P(Flu=True | S=\text{summer})P(S=\text{summer}) \\ = 0.14 \times 0.10 + 0.14 \times 0.10 = \boxed{0.14}$$

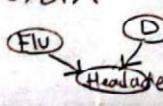
$$2. P(Flu=True | \text{Season}=\text{winter}) = \boxed{0.14}$$

$$3. P(Flu=True | \text{Season}=\text{winter}, \text{Headache}=\text{True}) = \frac{P(F=\text{True}, S=W, H=\text{True})}{P(S=W, H=\text{True})}$$

$$= \frac{\sum_d P(F=\text{True}, S=W, H=\text{True}, D=d)}{\sum_f P(F=f, S=W, H=\text{True}, D=d)} \rightarrow P(H=T | F=T, D=d)P(F=T | S=W)P(D=d | S=W) \\ \times P(S=W) \\ = \frac{\underbrace{0.14 \times 0.14 \times 0.10}_{0.14} + \underbrace{0.14 \times 0.14 \times 0.10}_{0.14}}{\underbrace{0.14 \times 0.14 \times 0.10}_{0.14} + \underbrace{0.14 \times 0.14 \times 0.10}_{0.14} + \underbrace{0.14 \times 0.14 \times 0.10}_{0.14} + \underbrace{0.14 \times 0.14 \times 0.10}_{0.14}} \\ = \boxed{0.14}$$

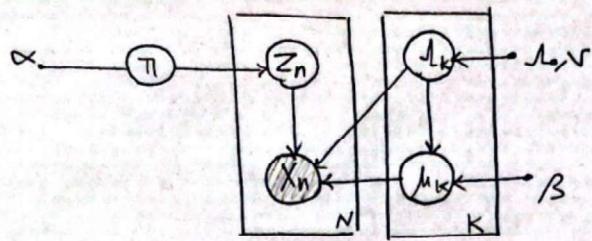
$$4. P(Flu=True | \text{Season}=\text{winter}, \text{Headache}=\text{True}, \text{Dehydration}=\text{True})$$

$$= \frac{P(F=\text{True}, S=W, H=\text{True}, D=\text{True})}{\sum_f P(F=f, S=W, H=\text{True}, D=\text{True})} \rightarrow P(H=T | F=T, D=T)P(F=T | S=W)P(D=T | S=W) \\ \times P(S=W) \\ = \frac{0.14 \times 0.14 \times 0.10}{0.14 \times 0.14 \times 0.10 + 0.14 \times 0.14 \times 0.10} = \boxed{0.14}$$

5. 
 Flu makes sense if dehydration
 Headache makes sense if dehydration

Problem ③:

Über alle \in Jobs j gehörenden Variablen $\rightarrow E$



$$\Rightarrow \pi_1, Z_1, \dots, Z_N, X_1, \dots, X_N, \lambda_1, \dots, \lambda_K, \lambda_o, \dots, \lambda_{o,r} \\ \text{const} + \sum_{i=1}^N \sum_{k=1}^K z_{ik} \log P(x_i | \mu_k, \lambda_k)$$

$$\log P(\lambda_j | \text{other}) = E_{-j} [\log P(\text{all})] + \text{const}$$

$$\log P(\text{all}) = \underbrace{\log P(\pi_1)}_{\text{const}} + \sum_{i=1}^N \underbrace{\log P(z_i | \pi_1)}_{\text{const}} + \sum_{i=1}^N \underbrace{\log P(x_i | z_i, \lambda_{zi}, \mu_{zi})}_{\text{constant } \lambda_{j,i} \text{ ist ausgenommen}} \\ + \underbrace{\sum_{i=1}^N \log P(\lambda_i)}_{\text{const} + \log P(\lambda_j)} + \underbrace{\sum_{i=1}^N \log P(\mu_i | \lambda_i)}_{\text{const} + \log P(\lambda_j | \lambda_i)}$$

$$\rightarrow P(x_i | z_i, \lambda, \mu) = \prod_{k=1}^K \left(P(x_i | \mu_k, \lambda_k) \right)^{z_{ik}} \quad z_i = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \rightarrow \text{Gamma sample component}$$

$$E_{-j} [\log P(\text{all})] + \text{const} = \log P(\lambda_j) + E_{\lambda_j} [\log P(\lambda_j | \lambda_j)] + \underbrace{E \left[\sum_{i=1}^N z_{ij} \log P(x_i | \mu_j, \lambda_j) \right]}_{\sum_{i=1}^N z_{ij} E[\log P(x_i | \mu_j, \lambda_j)]} \\ + \text{const 2}$$

$$+ \text{tr}(ABC) = \text{tr}(CAB) = \text{tr}(BCA) \quad \star \star$$

$$A = \beta_0 (\mu_k - \bar{x}_0)(\mu_k - \bar{x}_0)^T + W_0^{-1} + \sum_{n=1}^N r_{nk} (X_n - \mu_k)(X_n - \mu_k)^T \\ - \beta_k (\mu_k - \mu_k)(\mu_k - \mu_k)^T \quad \downarrow \quad \frac{1}{\lambda_j} \exp(-\lambda_j (x_i - \mu_j)^T \lambda_j (x_i - \mu_j)) \\ \frac{v_0 - D - 1 + \sum_{n=1}^N r_{nk}}{\nu} \ln |\lambda_k| - \frac{1}{\lambda_j} \text{Tr}[A \lambda_k]$$

$$= \log P(\lambda_j) + E_{\lambda_j} [\log P(\lambda_j | \lambda_j)] + \sum_{i=1}^N \alpha_i \frac{1}{\lambda_j} \text{tr}(A \lambda_j) \\ \downarrow \quad \text{Wishart}(\lambda_o, \nu) \quad \downarrow \quad - \frac{1}{\lambda_j} \text{tr}(E[(\mu_i - \mu_j)(\mu_i - \mu_j)^T] \lambda_j) \\ \quad \quad \quad A$$

$$\exp(-) P(\lambda_j | \text{other}) = \text{Wishart}(\lambda_o, \nu) + N(\mu_k | (\beta_k \lambda_k)^{-1}) + \text{Wishart}(\lambda', \nu') \\ \downarrow \quad \sum_{n=1}^N (X_n - \mu_k)(X_n - \mu_k)^T$$

$$\Rightarrow P(\lambda_j | \text{other}) = \text{Wishart} \left((\lambda_o^{-1} + \beta_k \mu_k \mu_k^T + \sum_{n=1}^N (X_n - \mu_k)(X_n - \mu_k)^T Z_n)^{-1}, \nu + 1 + \sum_{n=1}^N Z_{nk} \right) \\ \downarrow \quad \lambda' \sim \text{Beta}(\nu + \sum_{n=1}^N Z_{nk}) \\ \nu_k = \nu + 1 + \sum_{n=1}^N Z_{nk}$$

$$\log P(Z_{nk}=1 | \text{Other}) = E_{\pi_k} [\log P(\text{all})] + \text{const}$$

$$\begin{aligned}\log P(\text{all}) &= \underbrace{\log P(\pi)}_{\text{const}} + \sum_{i=1}^N \log P(Z_i | \pi) + \sum_{i=1}^N \log P(X_i | Z_i, \mu_{Z_i}, \lambda_{Z_i}) \\ &\quad + \underbrace{\sum_{i=1}^K \log P(\lambda_i)}_{\text{const}} + \underbrace{\sum_{i=1}^K \log P(\mu_i | \lambda_i)}_{\text{const}} \\ &= \sum_{i=1}^N \sum_{k=1}^K z_{ik} \log \pi_k + \sum_{n=1}^N \sum_{k=1}^K \log \left[N(X_n | \mu_k, \lambda_k^{-1}) \right] \times z_{nk} \\ &\quad - \frac{\lambda_k}{(y\pi)} \exp(-\frac{1}{\lambda_k} (x_n - \mu_k)^T \lambda_k (x_n - \mu_k))\end{aligned}$$

$$\begin{aligned}\Rightarrow \log P(Z_{nk}=1 | \text{Other}) &= E_{\pi} [\log P(Z | \pi)] + E_{\mu, \lambda} [\log P(X | Z, \mu, \lambda)] + \text{const} \\ &= \sum_{n=1}^N \sum_{k=1}^K z_{nk} \left(E[\log \pi_k] + \frac{1}{y} E[\log \lambda_k] - \frac{D \log(y\pi)}{y} \right. \\ &\quad \left. - \frac{1}{y} E_{\mu_k, \lambda_k} [(x_n - \mu_k)^T \lambda_k (x_n - \mu_k)] \right)\end{aligned}$$

$$P(Z_{nk}=1 | \text{Other}) = \prod_{n=1}^N \prod_{k=1}^K \frac{p_{nk}}{\sum_{i=1}^N p_{ni}} \left(E[\log \pi_k] + \frac{1}{y} E[\log \lambda_k] - \frac{D \log(y\pi)}{y} \right. \\ \left. - \frac{1}{y} E_{\mu_k, \lambda_k} [(x_n - \mu_k)^T \lambda_k (x_n - \mu_k)] \right)$$

$$P(Z_{nk}=1 | \text{Other}) \propto \prod_{n=1}^N \prod_{k=1}^K p_{nk} = \prod_{n=1}^N \prod_{k=1}^K \frac{p_{nk}}{\sum_{i=1}^N p_{ni}} \cdot \underbrace{\prod_{k=1}^K N(X_n | \mu_k, \lambda_k^{-1})}_{r_{nk} \propto \pi_k |\lambda_k|^{-1} \exp(-\frac{1}{\lambda_k} (x_n - \mu_k)^T \lambda_k (x_n - \mu_k))}$$

categorical distribution

$$\Rightarrow P(Z_{nk}=1 | \text{Other}) = \text{Categorical} \left(\frac{\sum z_1}{\sum z_K}, \dots, \frac{\sum z_K}{\sum z_K} \right)$$

$$\log(\pi | \text{other}) = E_{\pi} [\log P(\text{all})] + \text{const}$$

$$\begin{aligned}\log P(\text{all}) &= \log P(\pi) + \log P(z|\pi) + \sum_{i=1}^N \underbrace{\log P(x_i|z_i, \lambda_{z_i}, h_z)}_{\text{const}} \\ &\quad + \underbrace{\sum_{i=1}^k \log P(\lambda_i)}_{\text{const}} + \underbrace{\sum_{i=1}^k \log P(h_i|\lambda_i)}_{\text{const}}\end{aligned}$$

$\prod_{i=1}^N \prod_{k=1}^K \pi_k^{z_{ik}}$

$$\Rightarrow \log(\pi | \text{other}) = \underbrace{[\log P(\pi)]}_{\log c(\alpha_0) + \sum_{k=1}^K (\alpha_0 - 1) \log \pi_k} + E_{\pi} [\log P(z|\pi)] + \text{const}$$

$\sum_{i=1}^N \sum_{k=1}^K z_{ik} \log \pi_k$

$$\log P(\pi | \text{other}) = (\alpha_0 - 1) \sum_{k=1}^K \log \pi_k + \sum_{k=1}^K \sum_{i=1}^N E[z_{ik}] \log \pi_k + \text{const}$$

$\sum_{k=1}^K \log \pi_k [\alpha_0 - 1 + \sum_{i=1}^N r_{ik}]$

e(1) $\Rightarrow P(\pi | \text{other}) = \prod_k \left(\frac{\alpha_{k-1}}{\pi_k} \times \prod_{i=1}^N \pi_k^{r_{ik}} \right) + \text{const}$

$\Rightarrow P(\pi | \text{other}) = \text{Dirichlet} \left(\alpha_1 + \sum_{n=1}^N z_{n1}, \dots, \alpha_K + \sum_{n=1}^N z_{nk} \right)$

$$\text{Dirichlet} = \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_K)} \prod_{k=1}^K \pi_k^{\alpha_{k-1}}$$

$$\alpha_0 = \sum_{k=1}^K \alpha_k$$

$$\log P(\mu_k | \text{other}) = E_K \left[\log P(\text{all}) \right] + \text{const} \quad \text{const} + \sum_{i=1}^N Z_{ij} \log P(x_i | \mu_k, \Lambda_k)$$

$$\begin{aligned} \log P(\text{all}) &= \underbrace{\log P(\pi)}_{\text{const}} + \underbrace{\sum_{i=1}^N \log P(z_i | \pi)}_{\text{const}} + \underbrace{\sum_{i=1}^N \log P(x_i | z_i, \Lambda_z, \mu_z)}_{\text{const}} \\ &\quad + \underbrace{\sum_{i=1}^k \log P(\Lambda_i)}_{\text{const}} + \underbrace{\sum_{i=1}^k \log P(\mu_i | \Lambda_i)}_{\prod_{k=1}^K N(\mu_k | \mu_0, (\beta_0 \Lambda_k)^{-1})} \end{aligned}$$

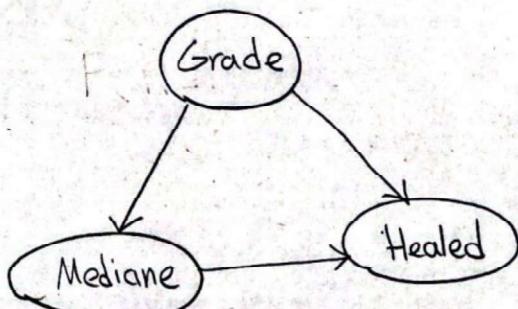
$$\log P(\text{all}) = \text{const} + \sum_{k=1}^K \left[\sum_{n=1}^N N(x_n | \mu_k, \Lambda_k^{-1}) Z_{nk} + N(\mu_k | \mu_0, (\beta_0 \Lambda_k)^{-1}) \right]$$

$$\Rightarrow P(\mu_k | \text{other}) = \exp \left(\sum_{k=1}^K \left[\underbrace{\sum_{n=1}^N N(x_n | \mu_k, \Lambda_k^{-1}) Z_{nk}}_{\text{as}} + \underbrace{N(\mu_k | \mu_0, (\beta_0 \Lambda_k)^{-1})}_{\propto} \right] \right)$$

$$\propto \exp \left[\mu_k^\top (\Lambda_k \sum_{n=1}^N X_n Z_{nk}) + (-\frac{1}{2} \mu_k^\top (\beta \Lambda_k + \Lambda_k \sum_{n=1}^N Z_{nk}) \mu_k) \right]$$

Problem ④:

	medicine A	medicine B
G ₁ : fatty liver grade 1	$\frac{11}{110} = 10\%$	$\frac{144}{200} = 72\%$
G=4, " " 4	$\frac{194}{244} = 79\%$	$\frac{80}{120} = 67\%$
Both	$\frac{11+194}{110+244} = \frac{205}{354} = 58\%$	$\frac{144+80}{200+120} = \frac{224}{320} = 70\%$



$$P(M, H, G) = P(G)P(M|G)P(H|M, G)$$

$$P(X_1, \dots, X_n | \text{dom}) = \prod_{i=1}^n P(X_i | PA_i(X_i))$$

$$P(\text{Healed} = \text{True} | \text{do}(\text{Med} = A)) = P(H=T | M=A, G=1)P(G=1) + P(H=T | M=A, G=4)P(G=4)$$

$$= \frac{11}{110} \times \frac{10 + 70}{200} + \frac{194}{244} \times \frac{70 + 10}{200} \approx 0.1844$$

$$P(\text{Healed} = \text{True} | \text{do}(\text{Med} = B)) = P(H=T | M=B, G=1)P(G=1) + P(H=T | M=B, G=4)P(G=4)$$

$$= \frac{144}{200} \times \frac{10 + 70}{200} + \frac{80}{120} \times \frac{70 + 10}{200} \approx 0.1718$$

* صدین هاین دارو A را در ترددی دارد و در این حالت ممکن است.

* صدین هاین دارو B را در ترددی درست نموده است.

این دارو بسیار محبوب است.

* آنچه نتایج بهتر نموده دارو B دار (83%) دار (17%) Healed rate دار (A) دار (10%) نتیجه دار A بهتر است.

Problem 5:

ابتدا کتابخانه های لازم را `import` کرده و داده های فایل `csv` را می خوانیم:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression

df = pd.read_csv("ngaussian (1).csv", delimiter=',', header=None)
```

شکل ۱- کتابخانه های مورد نیاز و خواندن داده ها

```
[3]:
```

	0	1
0	-1.727048	-3.599960
1	-1.445891	-3.270109
2	-0.458869	-1.148513
3	1.317966	2.516560
4	1.153506	2.006051
...
995	2.068504	5.060544
996	-2.633527	-5.427452
997	1.200837	1.701804
998	-2.797796	-5.378348
999	-1.159075	-1.555699

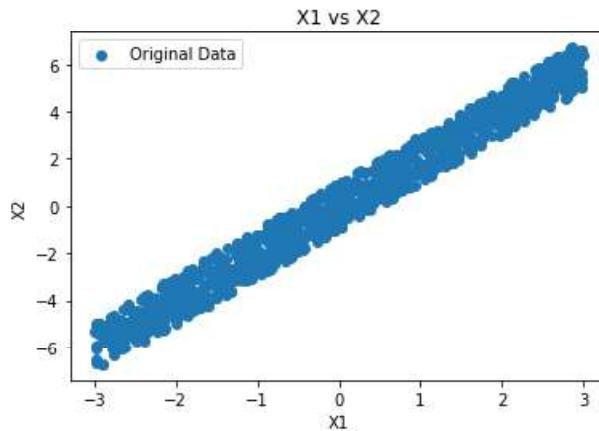
1000 rows × 2 columns

شکل ۲- نمایی از داده ها

نمایش داده ها به شکل زیر است:

```
4]: X1=df[0].values.reshape(-1, 1)
X2=df[1].values.reshape(-1, 1)

5]: plt.scatter(X1, X2 , label='Original Data')
plt.legend()
plt.xlabel('X1')
plt.ylabel('X2')
plt.title("X1 vs X2")
plt.show()
```



شکل ۳- نمایش داده ها

(a

در قسمت اول داده های X_2 را روی X_1 بصورت زیر فیت میکنیم و β_{12} را بدست می آوریم:

SCM M1

```
: model = LinearRegression(fit_intercept=False)

# Fit the model to the data
model.fit(X1, X2)

intercept = model.intercept_
slope12 = model.coef_[0]

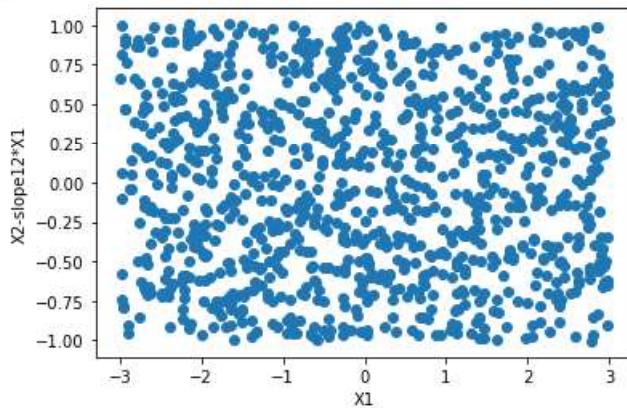
print(f"B12 is: {slope12}")

B12 is: [2.00326517]
```

شکل ۴- فیت داده ها قسمت اول

در این حالت $\beta_{12} = 0.326517$ بدست آمد. در مرحله بعدی X_1 را برحسب $X_2 - \beta_{12}X_1$ رسم میکنیم:

```
[9]: plt.scatter(X1, X2-slope12*X1)
plt.xlabel('X1')
plt.ylabel('X2-slope12*X1')
plt.show()
```



شکل ۵ - $X_2 - \beta_{12}X_1$ برحسب X_1

(b) بصورت مشابه قسمت قبل داده های X_1 را روی X_2 بصورت زیر فیت میکنیم و β_{21} را بدست می آوریم:

SCM M2

```
: model = LinearRegression(fit_intercept=False)

# Fit the model to the data
model.fit(X2, X1)

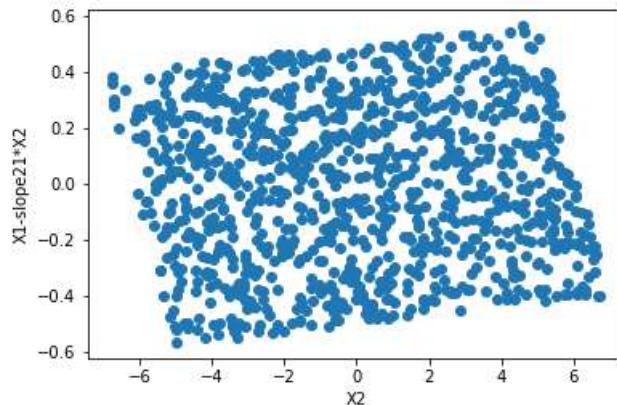
intercept = model.intercept_
slope21 = model.coef_[0]

print(f"\u03b2\u2082\u2081 is: {slope21}")
B21 is: [0.48538]
```

شکل ۶ - فیت داده ها قسمت دوم

در این حالت $\beta_{21} = 0.48538$ بدست آمد(عکس حالت قبل). در مرحله بعدی X_2 را برحسب $X_1 - \beta_{21}X_2$ رسم میکنیم:

```
12]: plt.scatter(X2, X1-slope21*X2)
plt.xlabel('X2')
plt.ylabel('X1-slope21*X2')
plt.show()
```



شکل ۷ - $X_1 - \beta_{21}X_2$ بر حسب

(c)

مدل با توزیع یکنواخت تر نمودار residual تناسب بهتری با داده ها فراهم می کند. یک نمودار residual توزیع شده به طور مساوی در نمودار اول نشان می دهد که مدل به طور دقیق رابطه بین X_1 و $X_2 - \beta_{12} * X_1$ را توضیح می دهد. این نشان می دهد که X_1 علت X_2 است، زیرا مدل به دقت تغییرات X_2 را بر اساس X_1 ثبت می کند. به عبارت دیگر، X_1 پیش بینی بهتری برای X_2 نسبت به عکس آن است. توزیع ناهموار نمودار دوم نشان می دهد که مدل در نشان دادن رابطه بین X_2 و $X_1 - \beta_{21} * X_2$ به اندازه کافی مؤثر نیست.

- رویکرد خطی-گاووسی معمولاً تنها به مجموعه‌ای از مدل‌های ممکن منتهی می‌شود که در ساختار همبستگی شرطی آنها معادل است.
- یک تنظیم خطی غیر گاووسی اجازه می دهد تا مدل علی کامل بدون پارامترهای نامشخص تخمین زده شود.